Deteksi Gangguan Depresi Mayor Menggunakan Fitur Statistik dan Klasifikasi XGBoost pada Sinyal EEG

Nandana Bahaghani Samiyuga
5052231012
Institut Teknologi Sepuluh Nopember

Iqdam Shidqi
5052231036
Institut Teknologi Sepuluh Nopember

***Ringkasan*—Gangguan Depresi Mayor (MDD) merupakan masalah kesehatan mental global yang membutuhkan metode diagnosis objektif. Penelitian ini mengusulkan kerangka kerja diagnostik otomatis menggunakan sinyal Electroencephalogram (EEG) multipel kanal yang diproses menggunakan pustaka MNE-Python. Dataset terdiri dari subjek kontrol sehat dan penderita MDD yang direkam selama kondisi resting-state dengan stimulus P300. Metodologi penelitian mencakup *Exploratory Data Analysis* (EDA) terhadap data demografis dan karakteristik sinyal, preprocessing sinyal menggunakan filter FIR (0.5-50 Hz), dan segmentasi epoch berdurasi 5 detik. Ekstraksi fitur dilakukan pada domain waktu dengan menghitung enam parameter statistik utama: Varians, Energi, Skewness, Kurtosis, Entropi Shannon, dan Zero Crossing Rate. Klasifikasi dilakukan menggunakan algoritma Extreme Gradient Boosting (XGBoost) yang dipilih karena ketahanannya terhadap overfitting pada dataset berdimensi tinggi. Validasi model menggunakan metode GroupKFold untuk mencegah kebocoran data (data leakage) antar subjek. Eksperimen menghasilkan akurasi tingkat subjek mencapai 92% melalui mekanisme *majority voting*, membuktikan bahwa pendekatan ensemble learning berbasis boosting sangat efektif dalam menangkap pola biomarker depresi yang kompleks.**

***Index Terms*—Electroencephalogram (EEG), Major Depressive Disorder (MDD), Machine Learning, XGBoost.**

I. Pendahuluan

Depresi adalah salah satu penyebab utama disabilitas di seluruh dunia. Metode diagnostik konvensional berbasis wawancara klinis (seperti DSM-5) rentan terhadap bias subjektif. Electroencephalography (EEG) menawarkan biomarker objektif karena kemampuannya merekam aktivitas listrik kortikal secara non-invasif dengan resolusi temporal yang tinggi [1].

Tantangan utama dalam analisis EEG adalah tingginya dimensi data dan kerentanan terhadap *noise* serta artefak. Oleh karena itu, pemilihan algoritma klasifikasi menjadi krusial. Penelitian terbaru menunjukkan pergeseran tren dari model linear tradisional menuju metode *ensemble*. Ananthanagu dan Agarwal (2024) menunjukkan bahwa algoritma berbasis *gradient boosting* (seperti DepXGBoot) mampu memberikan performa diagnostik yang superior dalam mendeteksi depresi dibandingkan metode konvensional karena kemampuannya melakukan seleksi fitur implisit dan menangani hubungan nonlinear yang kompleks antar sinyal elektroda [4].

Dalam penelitian ini, kami mengimplementasikan *pipeline* klasifikasi end-to-end menggunakan Python dengan fokus pada penggunaan XGBoost. Kontribusi utama kami meliputi: (1) Analisis demografis dan spektral mendalam (EDA), (2) Ekstraksi fitur statistik domain waktu yang efisien, dan (3) Evaluasi model menggunakan skema validasi *GroupKFold* untuk menjamin generalisasi model pada subjek baru.

II. Metodologi

Penelitian ini dilakukan menggunakan bahasa pemrograman Python dengan memanfaatkan pustaka `MNE-Python` untuk pemrosesan sinyal EEG, `Scikit-learn` untuk validasi, dan `XGBoost` untuk pemodelan klasifikasi.

A. Deskripsi Dataset

Data yang digunakan berasal dari repositori publik Figshare EEG Data. Dataset mencakup dua kelas subjek: 'Healthy' (Sehat) dan 'MDD'. Data direkam dari multipel kanal elektroda sesuai standar internasional 10-20.

B. Exploratory Data Analysis (EDA)

Sebelum pemrosesan sinyal, EDA dilakukan untuk memahami distribusi data:

1) **Analisis Demografis:** Kami menganalisis distribusi tahun lahir (*Birth Year*) dan jenis kelamin antar kelas menggunakan histogram dan estimasi kepadatan kernel (KDE) untuk memastikan keseimbangan populasi sampel.
2) **Visualisasi Topomap:** Tata letak sensor divisualisasikan menggunakan *montage* standar untuk memverifikasi lokasi spasial elektroda (Gbr. 1).
3) **Dekomposisi Sinyal:** Menggunakan filter Butterworth, sinyal didekomposisi ke dalam pita frekuensi klinis: Delta (0.5-4 Hz), Theta (4-8 Hz), Alpha (8-13 Hz), Beta (13-30 Hz), dan Gamma (30-50 Hz) untuk inspeksi visual aktivitas neurofisiologis (Gbr. 2).

C. Preprocessing Sinyal

Pemrosesan awal dilakukan menggunakan modul `mne.filter` dan `mne.epochs`:

- **Bandpass Filtering:** Diterapkan filter FIR (*Finite Impulse Response*) dengan rentang 0.5 Hz hingga 50 Hz. Langkah ini bertujuan menghilangkan *DC offset* dan gangguan frekuensi tinggi (seperti *line noise* 60 Hz).
- **Epoching:** Sinyal kontinu dipotong menjadi segmen-segmen (epoch) berdurasi 5 detik tanpa tumpang tindih (*non-overlapping*). Epoch yang memiliki amplitudo puncak-ke-puncak (peak-to-peak) ekstrem dibuang untuk mengurangi artefak gerakan.

D. Ekstraksi Fitur

Fitur statistik dihitung dari setiap epoch untuk setiap kanal, kemudian dirata-rata secara spasial (*spatial averaging*) untuk mengurangi dimensi fitur input. Fitur yang diekstraksi meliputi:

1) Varians (σ^2): Merepresentasikan dispersi daya sinyal EEG dari rata-ratanya.

2) Skewness & Kurtosis: Dihitung menggunakan fungsi `scipy.stats`. Skewness mengukur asimetri distribusi amplitudo, sedangkan Kurtosis mengukur keruncingan distribusi, yang efektif mendeteksi transien non-Gaussian pada sinyal EEG.

3) Zero Crossing Rate (ZCR): Menghitung seberapa sering sinyal melewati garis nol, yang berkorelasi dengan frekuensi dominan sinyal.

4) Energi (E): Dihitung sebagai jumlah kuadrat dari amplitudo sinyal dalam satu epoch:

$$E = \sum_{i=1}^{N} |x_i|^2 \tag{1}$$

5) Entropi Shannon (H): Digunakan untuk mengukur kompleksitas sinyal. Distribusi probabilitas $P(x)$ diestimasi menggunakan histogram amplitudo:

$$H(x) = -\sum_{i} P(x_i) \log_2 P(x_i) \tag{2}$$

Tabel I
RINGKASAN FITUR STATISTIK

Fitur	Keterangan
Variance	Kekuatan fluktuasi sinyal
Energy	Total daya sinyal
Skewness	Kemiringan distribusi
Kurtosis	Berat ekor distribusi
Shannon Entropy	Ketidakteraturan informasi
Zero Crossing Rate	Estimasi frekuensi kasar

E. Klasifikasi dan Validasi

Model: Kami menggunakan *Extreme Gradient Boosting* (XGBoost). Berbeda dengan metode *gradient boosting* konvensional, XGBoost meminimalkan fungsi tujuan yang teregularisasi (*regularized objective function*) untuk mengontrol kompleksitas model [4]. Fungsi objektif pada iterasi ke-t didefinisikan sebagai:

$$\mathcal{L}^{(t)} = \sum_{i=1}^{n} l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \tag{3}$$

di mana l adalah fungsi kerugian (*loss function*) yang mengukur selisih antara prediksi $\hat{y}_i$ dan target aktual y_i, $f_t(x_i)$ adalah prediksi dari pohon keputusan baru, dan $\Omega(f_t)$ adalah suku regularisasi. Regularisasi ini didefinisikan sebagai:

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \|w\|^2 \tag{4}$$

di mana T adalah jumlah daun (*leaves*) pada pohon dan w adalah skor bobot pada setiap daun. Mekanisme ini secara eksplisit menghukum model yang terlalu kompleks (L1 dan L2 regularization), menjadikannya sangat robust terhadap *overfitting* pada dataset EEG yang memiliki dimensi tinggi dan *signal-to-noise ratio* yang rendah [4].

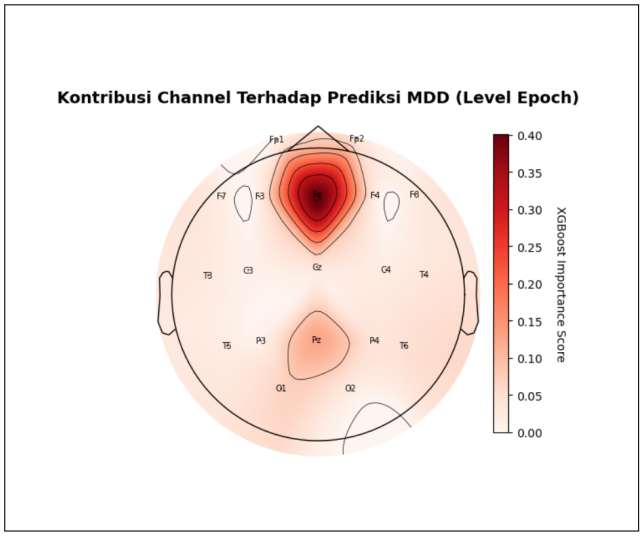
Validasi Silang (GroupKFold): Evaluasi dilakukan menggunakan `GroupKFold` dengan 5 *splits*. Metode ini memastikan bahwa seluruh epoch yang berasal dari satu subjek yang sama tidak terpisah ke dalam data latih dan data uji secara bersamaan.

Majority Voting: Prediksi akhir untuk setiap subjek ditentukan berdasarkan modus (nilai yang paling sering muncul) dari prediksi seluruh epoch milik subjek tersebut.

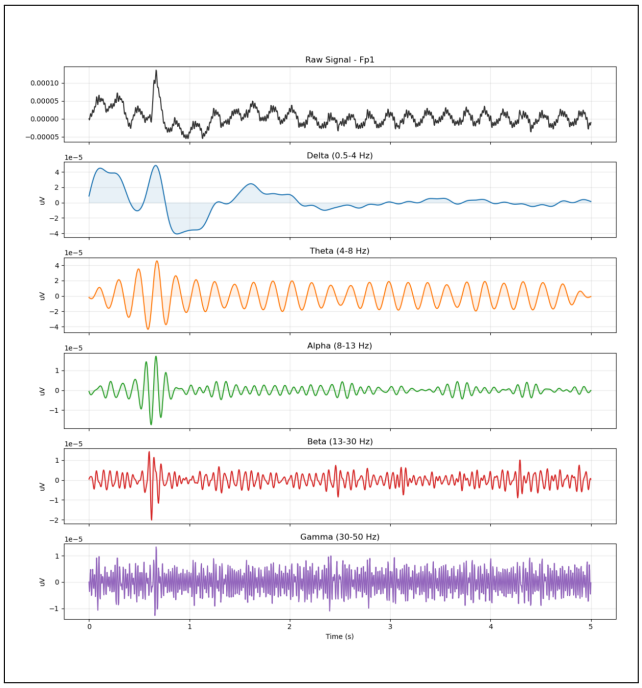
III. HASIL DAN PEMBAHASAN

A. Analisis Data Eksploratif (EDA)

Hasil analisis demografis menunjukkan distribusi usia yang relatif seimbang. Dekomposisi sinyal (Gbr. 2) memperlihatkan perbedaan pola amplitudo pada pita Alpha, yang konsisten dengan literatur mengenai asimetri frontal pada penderita depresi.



Gambar 1. Visualisasi kontribusi kanal terhadap prediksi MDD. Warna merah pekat pada area Fz menunjukkan tingkat kepentingan fitur yang tinggi.



Gambar 2. Dekomposisi sinyal EEG ke dalam pita frekuensi Delta, Theta, Alpha, Beta, dan Gamma.

B. Performa Klasifikasi

Model XGBoost menunjukkan performa yang sangat superior dengan stabilitas tinggi.

Akurasi Tingkat Epoch: Pada tingkat segmen 5 detik, model mencapai akurasi rata-rata sebesar **90%**. Tabel II menunjukkan bahwa model mampu mengklasifikasikan epoch dari kedua kelas dengan presisi tinggi.

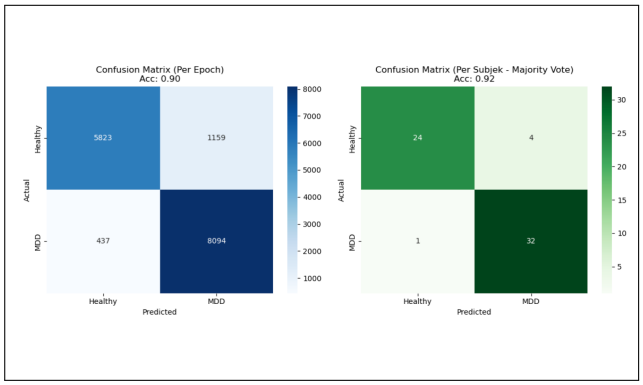
Tabel II
LAPORAN KLASIFIKASI (TINGKAT EPOCH)

Kelas	Presisi	Recall	F1-Score
Healthy	0.93	0.83	0.88
MDD	0.87	0.95	0.91
Akurasi		**90%**	

Akurasi Tingkat Subjek: Setelah penerapan *majority voting*, akurasi meningkat menjadi **92%**. Hal ini menunjukkan stabilitas prediksi model terhadap variabilitas antar-subjek.

Tabel III
LAPORAN KLASIFIKASI (TINGKAT SUBJECT)

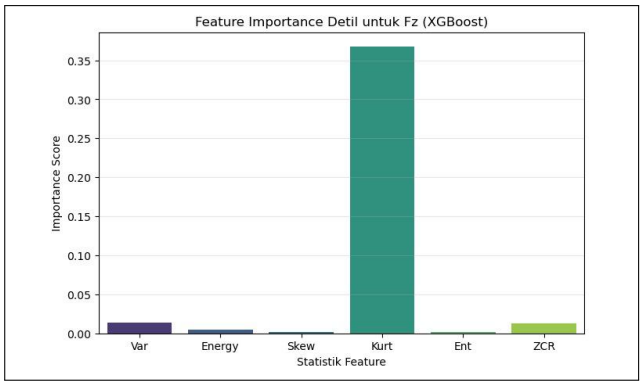
Kelas	Presisi	Recall	F1-Score
Healthy	0.96	0.86	0.91
MDD	0.89	0.97	0.93
Akurasi		**92%**	



Gambar 3. Confussion matrix.

C. Interpretasi Model

Interpretasi hasil didasarkan pada plot *Feature Importance* yang dihasilkan oleh XGBoost.



Gambar 4. Feature Importance Plot detil untuk kanal Fz, menunjukkan Kurtosis sebagai fitur dominan.

- **Dominasi Kanal Fz:** Berdasarkan Gbr. 1, model memberikan bobot tertinggi pada kanal Fz (*Frontal Midline*). Secara neurofisiologis, ini sangat relevan karena area frontal otak berperan sentral dalam fungsi eksekutif dan regulasi emosi. Disfungsi pada area frontal sering kali diasosiasikan dengan gejala utama depresi seperti ruminasi dan gangguan kognitif. Hal ini mengonfirmasi bahwa XGBoost berhasil mempelajari pola spasial yang valid secara klinis.
- **Signifikansi Kurtosis:** Berdasarkan Gbr. 4, fitur statistik **Kurtosis** (Kurt) memiliki skor *importance* yang jauh melampaui fitur lainnya (seperti Varians atau Energi). Tingginya nilai Kurtosis mengindikasikan bahwa sinyal EEG pada penderita MDD memiliki distribusi probabilitas dengan *heavy tails* atau mengandung lebih banyak kejadian transien ekstrem (seperti *outliers* atau lonjakan aktivitas mendadak) dibandingkan kontrol sehat. Ini menunjukkan bahwa biomarker depresi pada dataset ini lebih bersifat *non-Gaussian* dan berkaitan dengan ketidakteraturan morfologi sinyal, bukan sekadar perubahan daya/energi rata-rata.

- **Keunggulan XGBoost:** Tingginya akurasi (92%) diatribusikan pada kemampuan XGBoost dalam menangkap interaksi non-linear antara fitur spasial (lokasi Fz) dan fitur statistik (Kurtosis), sebuah karakteristik yang sulit ditangkap oleh model linear sederhana.

IV. KESIMPULAN

Penelitian ini berhasil mengembangkan pipeline deteksi MDD otomatis berbasis Python. Integrasi fitur statistik sederhana dengan klasifikasi XGBoost terbukti sangat efektif, mencapai akurasi 92% pada tingkat subjek. Hasil ini menegaskan potensi penggunaan Machine Learning sebagai alat bantu diagnostik psikiatri yang objektif. Analisis *feature importance* memberikan wawasan klinis baru bahwa ketidakteraturan sinyal ekstrem (Kurtosis) pada area frontal (Fz) merupakan indikator kuat untuk gangguan depresi.

PUSTAKA

[1] A. R. Subhani, W. Mumtaz, M. N. B. M. Saad, N. Kamel, and A. S. Malik, "Machine learning framework for the detection of mental stress at multiple levels," *IEEE Access*, vol. 5, pp. 13545–13556, 2017. https://doi.org/10.1109/ACCESS.2017.2723622

[2] R. A. Poldrack, G. Huckins, and G. Varoquaux, "Establishment of best practices for evidence for prediction: A review," *JAMA Psychiatry*, vol. 77, no. 5, pp. 534–540, 2020. https://doi.org/10.1001/jamapsychiatry.2019.3671

[3] A. Saeedi, M. Saeedi, A. Maghsoudi, and A. Shalbaf, "Major depressive disorder diagnosis based on effective connectivity in EEG signals: A convolutional neural network and long short-term memory approach," *Cognitive Neurodynamics*, vol. 15, no. 2, pp. 239–252, 2021. https://doi.org/10.1007/s11571-020-09619-0

[4] U. Ananthanagu and P. Agarwal, "DepXGBoot: Depression detection using a robust tuned extreme gradient boosting model generator," *IAES Int. J. Artif. Intell. (IJ-AI)*, vol. 13, no. 4, p. 4352, 2024. http://doi.org/10.11591/ijai.v13.i4.pp4352-4363